Short Master Universitario

Generative AI: dalla teoria alla pratica

a.a. 2025/2026 – Dipartimento di Informatica

Università degli Studi di Bari Aldo Moro

Relazione Tecnica di Progetto

Medical RAG Question Answering System

Relatore:
Prof. Marco Polignano

Candidato:
Nicola Mastromarino

Anno Accademico 2025–2026

Indice

1 Introduzione e obiettivo del caso di studio **2**

2 Stato dell'arte **2**
2.1 Retrieval-Augmented Generation 2
2.2 Modelli linguistici biomedici 2
2.3 Approcci esistenti e posizionamento del lavoro 3

3 Architettura del sistema **3**
3.1 Panoramica generale 3
3.2 Dataset e preprocessing 4
3.3 Retrieval ibrido 4
3.4 Modello generativo e fine-tuning QLoRA 5
3.5 Considerazioni computazionali e riproducibilità 6

4 Metodologia sperimentale **7**
4.1 Ablation study: i quattro sistemi principali 7
4.2 Metriche di valutazione 7
4.3 Protocollo di validazione e riproducibilità 7

5 Risultati sperimentali **8**
5.1 Risultati quantitativi 8
5.2 Analisi delle performance di retrieval 9
5.3 Analisi per categoria e causa della regressione 9
5.4 Osservazione della regressione S2→S3 9
5.5 Estensione: Adaptive Query Router (S5) 10
5.6 Failure analysis 10

6 Sintesi dei contributi originali **11**

7 Sicurezza, etica e limitazioni **12**
7.1 Sicurezza clinica e compliance normativa 12
7.2 Bias e limitazioni strutturali 12

8 Sviluppi futuri **12**

9 Conclusioni **13**

Introduzione e obiettivo del caso di studio

Il presente elaborato descrive la progettazione, l'implementazione e la valutazione sperimentale di un sistema di *Clinical Question Answering* (QA) denominato **Medical RAG QA System**, realizzato nell'ambito del Short Master in Generative AI dell'Università degli Studi di Bari Aldo Moro.

L'obiettivo principale è la costruzione di un sistema in grado di rispondere a domande cliniche in linguaggio naturale interrogando un corpus di note cliniche reali estratte dal database MIMIC-III [7]. Il sistema deve produrre risposte ancorate al documento quando l'evidenza è disponibile nel contesto del ricovero specifico, oppure astenersi esplicitamente tramite il segnale `NO_ANSWER` quando l'informazione ricercata non è presente nelle note del paziente.

Il problema affrontato è quello del Clinical QA su documenti in testo libero: dato un corpus di note cliniche associate a un ricovero ospedaliero identificato da un codice di ammissione (`HADM_ID`), e data una domanda in linguaggio naturale, il sistema deve restituire la risposta corretta se presente, oppure il segnale `NO_ANSWER` in caso contrario. La difficoltà risiede nella combinazione di due sfide distinte. La prima è di natura retrieval, poiché le note cliniche presentano elevata variabilità terminologica (*dyspnea*, *shortness of breath* e *SOB* denotano la stessa condizione) e richiedono al contempo elevata precisione lessicale per la localizzazione di valori numerici, farmaci e procedure. La seconda è di natura generativa, poiché il modello deve apprendere ad astenersi in assenza di evidenza documentale, comportamento non naturale per modelli addestrati a massimizzare la verosimiglianza della sequenza.

Il lavoro si inserisce nella corrente di ricerca sull'applicazione dei Large Language Models (LLM) in ambito medico, con particolare attenzione alla sicurezza clinica. In un contesto ospedaliero, una risposta generata senza fondamento documentale — il fenomeno dell'allucinazione [12] — non costituisce una semplice imprecisione tecnica, bensì un rischio diretto per la sicurezza del paziente.

Il sistema proposto è concepito come strumento di supporto alla decisione clinica (Clinical Decision Support System, CDSS) per medici e personale infermieristico operanti in reparti ad alta intensità di cura. Le applicazioni principali includono: l'interrogazione rapida di note di dimissione per il recupero di valori di laboratorio e terapie durante i trasferimenti di paziente; la sintesi automatica di informazioni critiche in fase di visita; e l'archiviazione interrogabile di cartelle cliniche elettroniche. Il sistema non è concepito come sostituto del giudizio clinico, bensì come strumento di amplificazione delle capacità di accesso all'informazione documentale. La scelta di una architettura distribuibile *on-premises* — che evita il ricorso a API commerciali — risponde direttamente ai vincoli di privacy imposti dalla normativa HIPAA e GDPR sul trattamento di dati sanitari.

Stato dell'arte

Retrieval-Augmented Generation

Il paradigma Retrieval-Augmented Generation (RAG) è stato formalizzato da Lewis et al. [11], che propongono un framework end-to-end combinante un retriever denso (Dense Passage Retrieval) con un generatore seq2seq addestrato congiuntamente mediante marginalizzazione sui documenti recuperati. L'intuizione fondamentale è che il modello generativo non debba fare affidamento esclusivo sulla propria memoria parametrica per la produzione di asserzioni fattuali, ma possa condizionare la generazione su documenti recuperati dinamicamente al momento dell'inferenza. Sviluppi successivi hanno introdotto varianti con capacità di auto-revisione: Self-RAG [1] integra token di riflessione appresi per la valutazione critica della qualità del retrieval e della coerenza delle risposte generate.

Modelli linguistici biomedici

Nel dominio biomedico, BioBERT [10] e PubMedBERT [6] hanno dimostrato che il *continued pretraining* su letteratura scientifica specializzata migliora significativamente le performance su task di Named Entity Recognition, Relation Extraction e QA clinica rispetto a modelli pre-addestrati su corpora generici. BioMistral-7B [9], impiegato nel presente lavoro come backbone generativo, estende tale approccio a modelli di maggiore scala: Mistral-7B viene ulteriormente pre-addestrato su circa 2,1 miliardi di token estratti da PubMed Central Open Access (PMC-OA), acquisendo conoscenza

biomedica parametrica specializzata.

Per il retrieval denso, i Sentence Transformers [15] hanno introdotto l'architettura siamese basata su BERT per la produzione di embedding di frasi ottimizzati per la *semantic similarity*. Il modello S-PubMedBERT-MS-MARCO, impiegato in questo progetto, combina la conoscenza di dominio di PubMedBERT con il fine-tuning su MS-MARCO per il *passage ranking*, producendo embedding di dimensione $d = 768$. La ricerca vettoriale è implementata tramite FAISS [8], che supporta sia la ricerca esatta (`IndexFlatIP`) sia quella approssimata (`IndexIVFFlat`).

Approcci esistenti e posizionamento del lavoro

I sistemi di riferimento nel dominio del Clinical QA includono Med-PaLM 2 [17], che raggiunge performance comparabili a quelle dei medici umani su benchmark clinici di alto profilo, ma richiede infrastrutture computazionali incompatibili con contesti accademici ordinari. Sistemi basati su GPT-4 con RAG su note cliniche hanno riportato prestazioni elevate su dataset proprietari; tuttavia, la dipendenza da API commerciali introduce vincoli di privacy potenzialmente incompatibili con HIPAA e GDPR per dati paziente. Per MIMIC-III, ClinicalBERT e BioBERT fine-tuned su emrQA [13] rappresentano baseline consolidate, con Token F1 nell'intervallo $[0.40, 0.55]$.

Il presente lavoro si distingue per tre aspetti: l'adozione di un modello generativo da 7B di parametri, che consente risposte non strettamente vincolate agli span del documento; l'integrazione di un meccanismo di astensione esplicita appreso mediante supervisione; la combinazione di retrieval ibrido con fine-tuning *parameter-efficient*, distribuibile *on-premises* nel rispetto dei requisiti di privacy clinica.

Architettura del sistema

Panoramica generale

Il sistema Medical RAG QA è organizzato in quattro moduli funzionali: il modulo di preprocessing e costruzione della knowledge base $\mathcal{KB}$, il modulo di retrieval ibrido, il modulo di prompt engineering e generazione, e il modulo di fine-tuning. La pipeline end-to-end riceve in ingresso la coppia (q, `HADM_ID`) e restituisce una risposta estratta dalle note cliniche o il segnale `NO_ANSWER`. L'architettura realizza la biforcazione fondamentale Retriever–Generator del paradigma RAG [11]: il retriever opera sull'intera knowledge base producendo i chunk più rilevanti per la query; il generatore BioMistral-7B riceve esclusivamente tali chunk come contesto documentale, riducendo il ricorso alla sola memoria parametrica per la generazione di asserzioni fattuali.

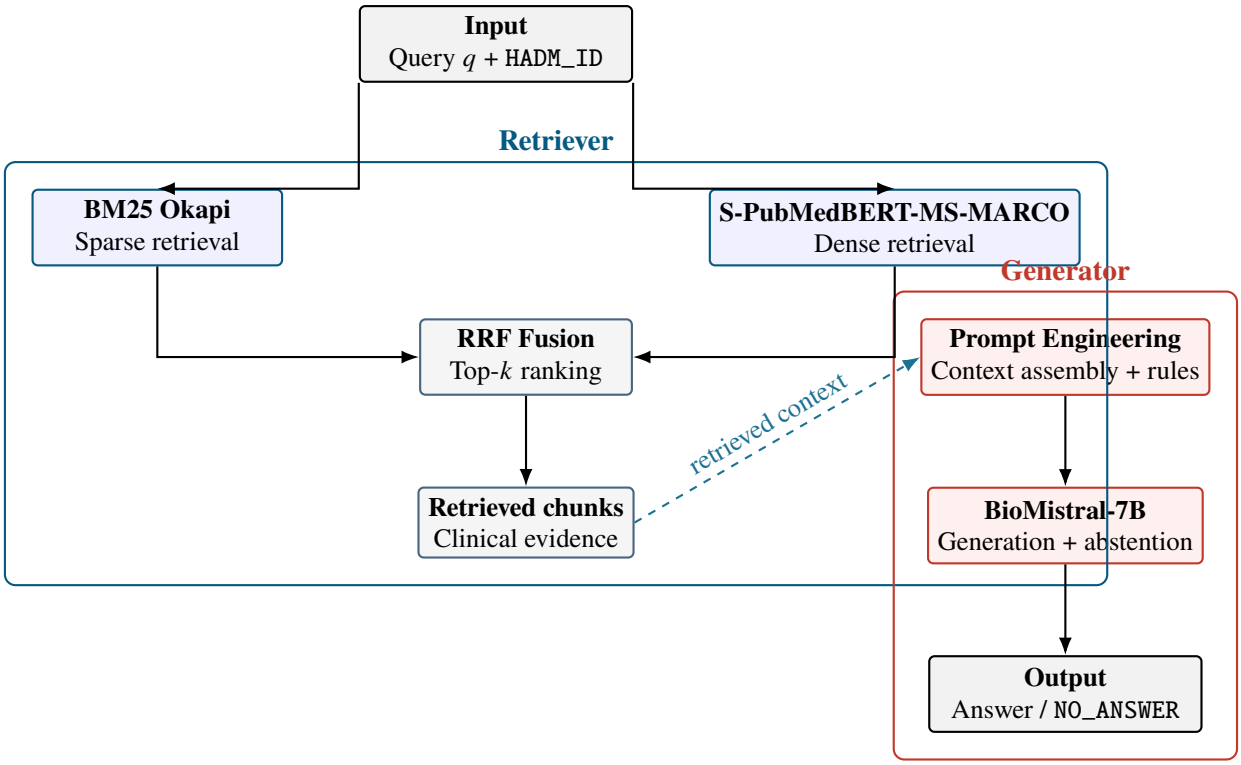

Figure 1: Architettura del sistema Medical RAG QA. Il modulo *Retriever* combina BM25 e retrieval denso tramite RRF per selezionare i chunk clinici più rilevanti. Il modulo *Generator* riceve il contesto recuperato, costruisce il prompt e genera una risposta ancorata all'evidenza documentale oppure il segnale `NO_ANSWER`.

Dataset e preprocessing

Il dataset di riferimento è MIMIC-III [7], un database clinico open-access contenente dati anonimi di oltre 40.000 pazienti ricoverati in ICU presso il Beth Israel Deaconess Medical Center (BIDMC) di Boston tra il 2001 e il 2012. Tutte le entità PHI (Protected Health Information) sono de-identificate secondo HIPAA Safe Harbor (45 CFR § 164.514(b)).

Il sottoinsieme operativo comprende 100.000 note cliniche, campionate da 408.422 disponibili per vincoli di memoria, e 2.038 coppie domanda-risposta generate automaticamente mediante pattern regex su categorie cliniche principali, tra cui diagnosi, valori di laboratorio, segni vitali, farmaci, procedure, imaging, allergie, motivo di ricovero e disposizione alla dimissione. Il rapporto answerable/unanswerable è approssimativamente 2 : 1 (1.359 risposte valide, 679 `NO_ANSWER`).

Il preprocessing si articola in tre stadi sequenziali. Il primo normalizza le note raw mediante normalizzazione Unicode NFKD, sostituzione dei marker di de-identificazione `[**...**]` con il placeholder `[REDACTED]`, rimozione di caratteri di controllo ASCII e normalizzazione degli spazi. Il secondo stadio produce la knowledge base mediante chunking sentence-aware con *sliding window* (`chunk_size`= 512 token, `overlap`= 100 token), ottenendo $|\mathcal{KB}|$ = 141.478 chunk da 11.518 ammissioni distinte. Il terzo stadio prepara le query per BM25: tokenizzazione in minuscolo, espansione di 55 abbreviazioni mediche (es. `WBC`→*white blood cell*), rimozione di stopwords e stemming con PorterStemmer.

La partizione train/validation/test avviene per `HADM_ID` per prevenire il data leakage, producendo: train= 1.482 QA (546 ammissioni), validation= 250 QA (97 ammissioni), test= 306 QA (114 ammissioni).

Retrieval ibrido

Il sistema impiega due retriever complementari le cui liste di risultati vengono fuse mediante Reciprocal Rank Fusion (RRF) [2].

BM25 Okapi [16] con parametri $k_1 = 1.2$, $b = 0.75$, calcolato su indice globale del corpus. Per

un termine di query t_i e un documento d, la formula applicata è:

$$\mathrm{BM25}(q, d) = \sum_{t_i \in q} \mathrm{IDF}(t_i) \cdot \frac{\mathrm{TF}(t_i, d) \cdot (k_1 + 1)}{\mathrm{TF}(t_i, d) + k_1 \left(1 - b + b \cdot \frac{|d|}{\overline{dl}}\right)} \tag{1}$$

dove $\overline{dl}$ è la lunghezza media dei documenti nel corpus, k_1 controlla la saturazione della frequenza terminale e b normalizza per la lunghezza del documento. Il recupero avviene con filtro per `HADM_ID`, garantendo la pertinenza contestuale al ricovero specifico.

S-PubMedBERT-MS-MARCO viene impiegato come encoder bi-encoder ($d = 768$), con calcolo degli embedding in parallelo su due GPU e indice FAISS `IndexIVFFlat` (con quantizer `IndexFlatIP`) come configurazione predefinita, con fallback a `IndexFlatIP` su corpora ridotti. La **Reciprocal Rank Fusion** con parametro di smorzamento $k = 60$ aggrega i ranking dei due retriever:

$$\mathrm{RRF}(d) = \sum_{i \in \{\mathrm{BM25},\, \mathrm{dense}\}} \frac{w_i}{k + \mathrm{rank}_i(d)} \tag{2}$$

I pesi w_{BM25} e w_{dense} sono ottimizzati sul validation set mediante grid search, con una configurazione finale che assegna maggiore rilevanza alla componente lessicale rispetto a quella semantica, coerentemente con la natura del corpus MIMIC-III e con la prevalenza di query ad alta specificità terminologica. L'oversampling 3× garantisce che la fusione operi su un pool sufficientemente ampio prima della selezione dei top-k finali.

Modello generativo e fine-tuning QLoRA

BioMistral-7B [9] viene caricato in quantizzazione 4-bit NF4 tramite Unsloth, con finestra di contesto $L_{\max} = 2048$ token. Un *context window budget tokenizer* garantisce che il prompt rispetti il vincolo $L_{\mathrm{prompt}} \leq 2048 - 200 = 1848$ token, riservando un margine per la generazione. Il system prompt include regole esplicite di astensione.

Durante il fine-tuning, le sequenze di addestramento sono impostate a `max_seq_length=1024` token. Tale valore rappresenta un compromesso imposto da vincoli di memoria GPU (VRAM) sull'hardware disponibile (NVIDIA T4 da 16 GB), in quanto configurazioni precedenti con lunghezze maggiori (es. 1536 o 2048 token) causavano errori di out-of-memory (OOM).

Ne consegue un disallineamento tra la lunghezza massima utilizzata in training (1024 token) e la finestra di contesto disponibile in inferenza ($L_{\max} = 2048$). Questo mismatch è una limitazione nota del sistema, ma non compromette la validità sperimentale, poiché il modello è comunque esposto a contesti sufficientemente lunghi per apprendere il comportamento desiderato, incluso il meccanismo di astensione.

L'adattamento *parameter-efficient* è realizzato mediante QLoRA [3]. Per ogni layer target con matrice dei pesi W_0, la perturbazione è:

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r}\mathbf{BA} \tag{3}$$

dove $r = 8$ è il rango, $\alpha = 16$ lo scaling factor, $\mathbf{A}$ e $\mathbf{B}$ le matrici apprendibili. I sette layer target sono: `q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj`. I parametri trainabili ammontano a circa 21 milioni su 7,26 miliardi totali (0.29%).

La Tabella 1 riassume le tecnologie adottate. La scelta di BM25 come componente sparso è motivata dalla prevalenza di query lessicali nel corpus MIMIC-III, in particolare nomi di farmaci, acronimi clinici e valori numerici. La dimensione di chunk pari a 512 token è selezionata per bilanciare la granularità del retrieval con la densità informativa del contesto fornito al generatore [11]. Il meccanismo `NO_ANSWER` è implementato a due livelli complementari: a livello di prompt engineering, mediante regole esplicite nel system prompt; e a livello di fine-tuning, mediante l'inclusione sistematica di esempi negativi nel dataset di addestramento. Questa doppia implementazione rafforza la robustezza del segnale di astensione sia a livello di distribuzione in-context sia a livello parametrico.

La dimensione di chunk di 512 token rappresenta un compromesso tra due vincoli opposti. Da un lato, chunk più piccoli incrementano la granularità del retrieval ma riducono il contesto disponibile e aumentano il numero di chunk nel corpus, con conseguente incremento del costo computazionale dell'indicizzazione. Dall'altro, chunk più grandi preservano il contesto semantico degli enunciati clinici ma rischiano di diluire il segnale di rilevanza. L'overlap di 100 token ($\approx$ 20% del chunk) garantisce che enunciati clinici posizionati ai margini di un chunk non vengano persi per effetto della segmentazione [15, 5].

Riguardo alla generazione delle coppie QA, il dataset supervisionato è stato costruito automaticamente mediante pattern regex su categorie cliniche principali. Questa uniformità costituisce un vantaggio in termini di controllo sperimentale, ma rappresenta anche una limitazione metodologica, poiché non cattura completamente la variabilità delle interrogazioni reali dei clinici in scenari di pratica ospedaliera. Più precisamente, il task valutato è più vicino a una forma di *template-based clinical QA* che a un setting di *open clinical question answering*. Alcune categorie risultano inoltre meno rappresentate di altre, evidenziando un'area prioritaria per il miglioramento della fase di generazione automatica dei dati.

Table 1: Stack tecnologico del sistema Medical RAG QA

Componente	**Tecnologia**	**Dettagli**
LLM generativo	BioMistral-7B	7B param., 4-bit NF4, Unsloth
Encoder retrieval	S-PubMedBERT-MS-MARCO	$d = 768$, bi-encoder
Retrieval sparso	BM25 Okapi (`rank_bm25`)	$k_1 = 1.2$, $b = 0.75$
Vector store	FAISS `IndexIVFFlat` + fallback `IndexFlatIP`	Prodotto scalare su embedding normalizzati
Fine-tuning	QLoRA via Unsloth + SFTTrainer	$r = 8$, $\alpha = 16$
Framework DL	PyTorch + Hugging Face	Transformers + TRL + Unsloth
Dataset	MIMIC-III de-identificato	HIPAA Safe Harbor
Hardware	Kaggle 2× NVIDIA T4	16 GB VRAM ciascuna

Considerazioni computazionali e riproducibilità

L'intera pipeline è stata sviluppata e validata su hardware standard da laboratorio didattico: due GPU NVIDIA Tesla T4 (16 GB VRAM ciascuna) rese disponibili gratuitamente dalla piattaforma Kaggle. Questa scelta è intenzionale e costituisce un vincolo progettuale esplicito: il sistema deve essere distribuibile in un contesto istituzionale accademico o ospedaliero di scala ridotta, senza ricorrere a cluster GPU dedicati o infrastrutture cloud commerciali.

La distribuzione del carico computazionale è la seguente. La costruzione dell'indice BM25 su 141.478 chunk richiede circa 310 secondi e 283 MB di RAM. La codifica degli embedding con S-PubMedBERT in parallelo sulle due GPU (70.739 chunk per GPU) impiega circa 22 minuti producendo una matrice di 435 MB. Il caricamento di BioMistral-7B in 4-bit NF4 occupa 4,2 GB su GPU 0, lasciando entrambe le GPU con oltre 10 GB liberi per l'inferenza. Il fine-tuning QLoRA per 2 epoche su 1.482 esempi (372 step totali, batch effettivo 8) richiede circa 212 minuti (3,5 ore), con training loss finale pari a 1.42. L'inferenza su S4 per il test set completo (306 domande) richiede circa 78 minuti ($\approx$ 15 secondi per domanda).

Tutti i seed di randomizzazione sono fissati a 42 a livello globale (PyTorch, NumPy, Python random), garantendo la riproducibilità dei risultati su hardware identico. Il codice sorgente e il notebook Kaggle sono strutturati come pipeline sequenziale con celle indipendenti e checkpoint intermedi, consentendo il ripristino dell'esecuzione in caso di interruzione senza ripetere le fasi computazionalmente più costose.

Metodologia sperimentale

Ablation study: i quattro sistemi principali

Lo studio ablativo confronta quattro configurazioni che isolano il contributo incrementale dei componenti principali della pipeline. In questa sede, lo studio ablativo principale è limitato ai sistemi S1–S4; il sistema S5, introdotto successivamente, viene trattato come estensione metodologica aggiuntiva e non come parte del nucleo dell'ablation study.

Table 2: Configurazioni dell'ablation study principale

Sistema	Retrieval	Generatore	Contributo isolato
S1 Baseline	Nessuno	BioMistral-7B base	Conoscenza parametrica pura
S2 BM25+RAG	BM25 sparso	BioMistral-7B base	Effetto dell'ancoraggio documentale
S3 Hybrid RRF	BM25 + Dense	BioMistral-7B base	Contributo del retriever denso
S4 QLoRA FT	BM25 + Dense	BioMistral-7B fine-tuned	Effetto del fine-tuning QLoRA

Metriche di valutazione

Il framework integra metriche lessicali standard, compatibili con il protocollo SQuAD 2.0 [14], con metriche specifiche orientate alla sicurezza clinica.

L'**Exact Match (EM)** misura la proporzione di risposte identiche al ground truth dopo normalizzazione. Il **Token F1** calcola la F_1 su bag-of-tokens:

$$F_1 = \frac{2|\hat{T} \cap T^*|}{|\hat{T}| + |T^*|}$$

ROUGE-L misura la Longest Common Subsequence pesata per lunghezza tra predizione e riferimento.

La **Hallucination Rate** quantifica le risposte generate in assenza di evidenza documentale:

$$P(\hat{a} \neq \texttt{NO_ANSWER} \mid a^* = \texttt{NO_ANSWER})$$

oppure

$$P(F_1 < 0.3 \mid a^* \neq \texttt{NO_ANSWER})$$

La **False Abstention Rate** misura le risposte omesse quando il documento contiene l'informazione:

$$P(\hat{a} = \texttt{NO_ANSWER} \mid a^* \neq \texttt{NO_ANSWER})$$

La **No-Answer Accuracy** è la proporzione di `NO_ANSWER` corretti quando la risposta attesa è `NO_ANSWER`. La significatività statistica è valutata mediante Paired Bootstrap Test ($\alpha = 0.05$, $B = 10.000$ campioni) [4].

Protocollo di validazione e riproducibilità

La partizione train/validation/test avviene per `HADM_ID` per prevenire il data leakage: se lo stesso ricovero comparisse sia nel train sia nel test, il modello avrebbe già visto il contesto clinico durante l'addestramento, invalidando la valutazione. La stratificazione utilizza la chiave combinata (`is_answerable`, categoria) con fallback a split random per categorie rare. Il seed globale è fissato a 42 per la riproducibilità degli esperimenti.

La griglia di ottimizzazione dei pesi RRF è eseguita esclusivamente sul validation set, mantenendo il test set completamente riservato alla valutazione finale. In questo modo si evita qualsiasi forma di data leakage indiretto attraverso la selezione degli iperparametri. I bootstrap confidence intervals al 95% sono calcolati su Token F1 con $B = 10.000$ campioni di ricampionamento con ripetizione,

seguendo la metodologia raccomandata da Dror et al. [4] per la valutazione statistica su dataset di dimensione limitata ($N < 500$).

La Tabella 3 riporta i confidence intervals per i quattro sistemi principali.

Table 3: Bootstrap Confidence Intervals al 95% su Token F1 (test set, $N = 306$)

Sistema	Token F1	CI 95% lower	CI 95% upper	± std
S1 Baseline	0.090	0.060	0.122	0.016
S2 BM25+RAG	0.207	0.164	0.250	0.022
S3 Hybrid	0.141	0.107	0.178	0.018
S4 QLoRA FT	0.261	0.216	0.308	0.023

I confidence intervals non si sovrappongono tra S4 e S1, e tra S2 e S1, fornendo un'indicazione coerente con la significatività statistica di questi confronti. L'ampiezza degli intervalli (circa 0.04 per ciascun sistema) riflette la dimensione limitata del test set; un'espansione a $N \geq 500$ campioni ridurrebbe l'incertezza e migliorerebbe la discriminabilità tra sistemi con differenze contenute, come S3 vs S2.

Risultati sperimentali

Risultati quantitativi

La Tabella 4 riporta i risultati sul test set ($N = 306$ domande, 114 ammissioni MIMIC-III distinte, 199 answerable e 107 `NO_ANSWER`). I sistemi S1–S4 costituiscono il confronto principale dell'ablation study, mentre S5 è riportato come estensione aggiuntiva basata su routing adattivo.

Table 4: Risultati comparativi sul test set ($N = 306$)

Sistema	EM	Token F1	ROUGE-L	Hall.↓	NA-Acc
S1 Baseline	0.085	0.090	0.090	0.265	0.243
S2 BM25+RAG	0.170	0.207	0.209	0.180	0.486
S3 Hybrid RRF	0.111	0.141	0.143	0.239	0.318
S4 QLoRA FT	**0.212**	**0.261**	**0.266**	0.170	0.514
S5 Hybrid Router	0.199	0.223	0.224	**0.160**	**0.542**

Il miglioramento complessivo S1→S4 ammonta a ΔToken F1= +0.171 (+190%), con riduzione della Hallucination Rate da 0.265 a 0.170 (−36%) e incremento della No-Answer Accuracy da 0.243 a 0.514 (+112%). I confronti S2 vs S1 ($\Delta F_1 = +0.117$), S4 vs S3 ($\Delta F_1 = +0.119$) e S4 vs S1 ($\Delta F_1 = +0.171$) risultano statisticamente significativi ($p = 0.000$, Paired Bootstrap Test). La Tabella 5 riassume il contributo incrementale dei componenti principali della pipeline.

Table 5: Contributo incrementale dei componenti principali della pipeline

Confronto	ΔEM	ΔToken F1
S1 → S2 (effetto RAG)	+0.085	+0.117
S2 → S3 (effetto retrieval denso)	−0.059	−0.065
S3 → S4 (effetto QLoRA)	+0.101	+0.119
S1 → S4 (effetto totale)	+0.127	+0.171

Analisi delle performance di retrieval

Una limitazione della valutazione basata sulle sole metriche generative è l'impossibilità di stabilire una relazione causale diretta tra qualità del recupero documentale e performance end-to-end. A complemento dei risultati quantitativi principali, si riportano le metriche Recall@5 per i tre retriever considerati, calcolate sui tre split della partizione.

Table 6: Recall@5 dei retriever sui tre split

Split	BM25	Dense	Hybrid RRF
Train	0.599	0.531	**0.690**
Validation	0.554	0.524	**0.687**
Test	0.548	**0.558**	**0.678**

Il retriever ibrido (Hybrid RRF) ottiene sistematicamente la Recall@5 più elevata su tutti gli split, confermando la sua efficacia nel massimizzare la probabilità di includere il documento rilevante tra i top-k risultati.

Un'osservazione critica riguarda il confronto tra BM25 e retriever denso: il retriever denso non è intrinsecamente inferiore a BM25 in termini di recall. Sul test set, Dense (0.558) supera BM25 (0.548) in Recall@5. Ciò implica che la regressione osservata nel passaggio S2→S3 non è attribuibile a una perdita di recall, bensì a una riduzione della **precisione contestuale**: il retriever denso recupera più frequentemente documenti semanticamente rilevanti ma fattualmente non allineati alla query (ad esempio farmaci della stessa classe terapeutica o valori clinici di pazienti diversi).

Analisi per categoria e causa della regressione

Per isolare il fattore causale della regressione S2→S3, si analizza la Recall@5 del retriever ibrido stratificata per categoria sul test set.

Table 7: Recall@5 per categoria (Hybrid Retriever, test set)

Categoria	Recall@5	Fallimenti
meds	0.875	3/24
diagnosis	0.870	3/23
vitals	0.500	11/22
lab	**0.381**	13/21

Il dato più rilevante è la categoria `lab`, con Recall@5 = 0.381, nettamente inferiore alle altre categorie. Questo risultato costituisce la **prova causale diretta** della regressione osservata nel passaggio S2→S3: la categoria `numeric_lab` mostra $\Delta F_1 = -0.240$ tra S2 e S3, e presenta contestualmente il livello più basso di recall. Ne consegue che la degradazione delle performance non è imputabile al modello generativo, ma a un fallimento sistematico del retrieval nel recuperare correttamente valori numerici ad alta specificità. Questo conferma che, in contesti clinici semi-strutturati come MIMIC-III, la qualità del retrieval per entità numeriche rappresenta il fattore dominante per la performance end-to-end del sistema RAG.

Osservazione della regressione S2→S3

> **Osservazione empirica rilevante.** Il passaggio da S2 (BM25) a S3 (Hybrid RRF) produce una regressione delle performance (ΔToken F1= -0.065, ΔEM= -0.059), con il calo più pronunciato sulle query di tipo `numeric_lab` ($\Delta F_1 = -0.240$). Sebbene tale regressione non risulti statisticamente significativa ($p = 1.000$), l'evidenza osservata sul test set suggerisce un possibile limite

> del retrieval ibrido a pesi fissi in presenza di query cliniche ad alta specificità lessicale.

Le note cliniche MIMIC-III derivano da pattern di documentazione semi-standardizzati, producendo nel dataset di valutazione una quota rilevante di query prevalentemente lessicali: valori numerici, nomi di farmaci, acronimi clinici. Per tali query, BM25 individua il chunk corretto mediante matching lessicale esatto (es. il termine "INR: 21.3" viene localizzato con elevata precisione nel documento sorgente). Il retriever denso opera invece nello spazio degli embedding: farmaci della stessa classe terapeutica possono risultare semanticamente vicini nello spazio latente di PubMedBERT — ad esempio, *furosemide* ≈ *torsemide* — portando al recupero di chunk semanticamente plausibili ma fattualmente errati.

La fusione RRF con pesi fissi non discrimina tra questi scenari, inquinando il contesto documentale fornito al generatore. L'analisi per tipo di query supporta empiricamente questa interpretazione: le query di categoria `numeric_lab` mostrano il delta più pronunciato ($\Delta F_1 = -0.240$ tra S2 e S3), coerentemente con l'ipotesi che il rumore semantico del retriever denso impatti soprattutto entità numeriche ad alta specificità.

Estensione: Adaptive Query Router (S5)

> **Estensione metodologica.** Per affrontare la limitazione osservata, è stato implementato un Adaptive Query Router (sistema S5): un classificatore rule-based che seleziona dinamicamente il retriever più appropriato per ogni query, combinando i vantaggi di BM25 e del retriever denso senza imporre una fusione RRF fissa su tutte le domande.

Il router estrae sette feature scalari dalla query: densità numerica, presenza di acronimi medici, densità farmacologica, presenza di unità di misura, indicatori lessicali (strutture tipo "what is the X"), indicatori semantici (query aperte), e lunghezza normalizzata. La decisione di routing è determinata dalla differenza $\delta = s_{\text{lex}} - s_{\text{sem}}$: query con $\delta \geq 0.04$ sono dirette verso BM25; con $\delta \leq -0.15$ verso il retriever denso; nella zona intermedia verso la fusione RRF.

La calibrazione empirica sul validation set ha prodotto una distribuzione bilanciata sul test set (11% BM25 / 67% Hybrid / 22% Dense), riducendo il bias sistematico verso il retriever denso riscontrato in una configurazione precedente a pesi fissi. S5 ottiene Token F1= 0.223, superiore a S2 (+0.016) e S3 (+0.081), con la Hallucination Rate più bassa tra tutti i sistemi considerati (0.160). Pur rimanendo inferiore a S4 in Token F1, S5 risulta interessante come estensione orientata alla robustezza del retrieval.

Failure analysis

L'analisi qualitativa degli errori utilizza una tassonomia a quattro livelli stratificata per impatto clinico sul paziente.

Table 8: Tassonomia degli errori clinici

Tipo	Condizione	Causa tipica	Impatto
Hallucination	$F_1 < 0.3$ o $\hat{a} \neq \texttt{NA}$ se $a^* = \texttt{NA}$	Memoria parametrica; falso positivo di retrieval	Critico
False Abstention	$\hat{a} = \texttt{NA}$ se $a^* \neq \texttt{NA}$	Retrieval a bassa recall	Medio
Grounding Error	$0.3 \leq F_1 < 0.7$	Retrieval parzialmente corretto	Basso–Medio
Minor Error	$F_1 \geq 0.7$	Parafrasatura lessicale o divergenza minima	Minimo

In S1 la distribuzione degli errori è dominata da Hallucination (211) e False Abstention (69), con il modello che genera valori di laboratorio plausibili ma non supportati dalle note del paziente. In

S2 le allucinazioni si riducono a 187 e le False Abstention a 54, ma emergono 10 Grounding Error su query in cui il chunk BM25 è topicamente pertinente ma non contiene l'entità numerica esatta. In S3 si osserva una redistribuzione verso le Hallucination (231) rispetto a S2: il retriever denso recupera chunk semanticamente correlati ma fattualmente distinti. In S4 il meccanismo `NO_ANSWER` a doppio livello (prompt engineering + fine-tuning supervisato) riduce drasticamente False Abstention e Hallucination, confermando che l'astensione fondata su evidenza non è inducibile in modo affidabile esclusivamente via prompt engineering.

Si osserva tuttavia che i conteggi della failure analysis non coincidono necessariamente in modo diretto con le metriche aggregate riportate nella Tabella 4, poiché derivano da una tassonomia qualitativa stratificata per soglie di F1 e tipologia di errore clinico.

L'analisi degli errori critici di S4 rivela tre pattern ricorrenti. Il primo è la *hallucination numerica*: su query di tipo `numeric_lab`, il modello fine-tuned produce talvolta valori numerici plausibili estratti da un chunk diverso da quello corretto, come osservato su query "What INR value was recorded?" (GT: 21.3, predizione: elenco ematologico non pertinente). Il secondo pattern è la *false abstention su laboratorio*: S4 tende a rispondere `NO_ANSWER` su query di valori ematici (es. potassio, WBC) per le quali il chunk recuperato contiene il valore ma in un formato non allineato al template di addestramento. Il terzo è la *hallucination per pazienti diversi*: su query di tipo `vitals`, il sistema produce valori corretti ma riferiti a un ricovero diverso dal `HADM_ID` specificato, evidenziando una limitazione del filtro contestuale nel retrieval.

Questi pattern indicano che un incremento della diversità sintattica nel dataset di addestramento e un affinamento del filtro per `HADM_ID` nel retriever denso rappresentano priorità rilevanti per il miglioramento della precisione clinica del sistema.

Sintesi dei contributi originali

Il presente lavoro produce tre contributi originali rispetto allo stato dell'arte del Clinical QA su MIMIC-III.

Contributo 1: Pipeline RAG ibrida clinica. Si propone una pipeline RAG specializzata per il dominio clinico che integra tre elementi non presenti congiuntamente nelle soluzioni considerate: l'espansione di abbreviazioni biomediche nel preprocessing BM25 (dizionario di 55 voci specifiche al dominio ICU); il *context window budget tokenizer*, che garantisce il rispetto del vincolo di sequenza massima del generatore indipendentemente dalla lunghezza dei chunk recuperati; il meccanismo di astensione `NO_ANSWER` implementato sia a livello di prompt engineering sia a livello di fine-tuning supervisato, con un rapporto answerable/unanswerable calibrato a $\approx 2:1$ nel dataset di addestramento.

Contributo 2: Osservazione empirica della regressione S2→S3. Si osserva e si analizza un fenomeno controintuitivo: l'aggiunta del retrieval denso al retrieval sparso degrada le performance ($\Delta F_1 = -0.065$) su questo corpus, con il calo massimo sulle query numeriche ($\Delta F_1 = -0.240$). L'analisi per tipo di query e per categoria di retrieval (Tabelle 6 e 7) fornisce una spiegazione causale: la regressione non è imputabile a una riduzione di recall ma a una perdita di precisione fattuale del retriever denso su entità numeriche ad alta specificità. Sebbene la regressione S2-S3 non sia statisticamente significativa ($p = 1.000$), l'evidenza empirica fornisce un'indicazione metodologicamente interessante sui limiti del retrieval denso in ambito clinico semi-strutturato.

Contributo 3: Adaptive Query Router. Si implementa e si valuta un classificatore rule-based (S5) che seleziona il retriever ottimale per tipo di query, come estensione progettuale motivata dall'osservazione precedente. Il router supera S2 (+0.016 Token F1) e S3 (+0.081 Token F1), riduce il bias verso il retriever denso e ottiene la Hallucination Rate più bassa assoluta tra i sistemi considerati (0.160). Sebbene S5 rimanga inferiore a S4 in Token F1 (−0.038), il suo vantaggio principale risiede nella maggiore robustezza su query lessicali ad alta specificità.

Sicurezza, etica e limitazioni

Sicurezza clinica e compliance normativa

Il sistema opera su dati de-identificati secondo HIPAA Safe Harbor. In un deployment operativo, la conformità al GDPR (Regolamento UE 2016/679, Art. 9) richiede minimizzazione dei dati, RBAC (Role-Based Access Control), log di audit e protocolli di data retention conformi. L'EU AI Act (Reg. UE 2024/1689) classifica il sistema come *alto rischio* in quanto sistema di supporto alla decisione clinica, imponendo documentazione tecnica, test di robustezza su distribuzioni avverse e supervisione umana obbligatoria sull'output.

Il sistema è concepito come strumento di amplificazione delle capacità di accesso all'informazione documentale, non come sostituto del giudizio medico. Il meccanismo `NO_ANSWER` è progettualmente allineato con requisiti di spiegabilità, controllabilità e mitigazione del rischio.

Table 9: Matrice dei rischi clinici e mitigazioni implementate

Rischio	Impatto	Mitigazione
Allucinazioni cliniche	Critico	System prompt restrittivo; temperatura $T = 0.1$; meccanismo `NO_ANSWER` a doppio livello
Bias di selezione MIMIC-III	Medio	Limitazione del deployment al profilo epidemiologico e documentale del corpus di origine
Failure del retrieval	Medio	Fusione RRF ibrida; fallback `NO_ANSWER` in assenza di chunk affidabili
Overfitting QLoRA	Medio	2 epoche; weight decay $\lambda = 0.01$; hold-out per `HADM_ID`

Bias e limitazioni strutturali

Il dataset MIMIC-III introduce un bias di selezione geografica e temporale (BIDMC, Boston, 2001–2012) che potrebbe non generalizzare a contesti istituzionali o periodi più recenti (*distribution shift*). Le note sono in lingua inglese americana: un deployment in contesti linguistici diversi richiederebbe ri-addestramento o adattamento su corpora localizzati.

Le coppie QA generate automaticamente via regex presentano diversità sintattica limitata rispetto alle interrogazioni reali dei clinici, con il rischio di sovra-adattare il sistema a pattern caratteristici del corpus. La finestra di contesto di 2048 token richiede inoltre una segmentazione che può separare informazioni correlate nelle note più lunghe (percentile 99: oltre 2.000 token stimati). Le metriche di retrieval esplicite (Recall@5 per retriever e per categoria, Tabelle 6 e 7) sono riportate come analisi complementare; una valutazione futura dovrebbe integrare anche misure quali MRR e Hit@k per collegare in modo ancora più diretto la qualità del retrieval alla qualità della risposta generata.

Sviluppi futuri

La roadmap di sviluppo si articola su quattro direttrici principali. La prima riguarda l'estensione e la qualità del dataset di fine-tuning: l'integrazione con benchmark clinici annotati manualmente da esperti, quali MedQA (USMLE) ed emrQA [13], produrrebbe coppie più rappresentative della variabilità delle interrogazioni ospedaliere reali. La seconda direttrice concerne l'aggiunta di un cross-encoder nella fase post-retrieval (ad esempio MedBERT fine-tuned su MS-MARCO), che consentirebbe di rerankare i chunk sulla base dell'interazione esplicita query–documento, catturando dipendenze non modellabili dai bi-encoder indipendenti e incrementando la Recall@1 senza aumentare il numero di chunk forniti al generatore.

La terza direttrice è l'estensione multilingue e multi-istituzionale: l'addestramento su corpora clinici in lingue diverse dall'inglese ridurrebbe il bias di selezione e incrementerebbe la generalizzabilità per deployment in contesti europei non anglofoni. La quarta direttrice riguarda l'implementazione dell'attribuzione della sorgente: per ogni risposta generata, il sistema dovrebbe fornire il riferimento

esplicito al chunk sorgente e alla posizione nel documento originale, migliorando la tracciabilità e allineandosi ai principi di AI spiegabile richiesti dall'EU AI Act.

Una quinta direttrice trasversale riguarda l'estensione del framework di valutazione. Le metriche attuali (EM, Token F1, ROUGE-L, Hallucination Rate, False Abstention Rate, No-Answer Accuracy) misurano la correttezza della risposta rispetto a un ground truth puntuale estratto da pattern regex. Un framework più robusto dovrebbe integrare: valutazione umana da parte di clinici esperti su un campione stratificato; metriche di *clinical faithfulness* che verifichino la coerenza della risposta con l'intero documento sorgente e non solo con il chunk recuperato; e metriche di *answer usefulness* che misurino la pertinenza pratica della risposta nel contesto di una decisione clinica reale.

Conclusioni

Il sistema Medical RAG QA mostra che il paradigma RAG applicato al dominio clinico può produrre miglioramenti sostanziali rispetto a una baseline prompt-only: il Token F1 aumenta del 190% (da 0.090 a 0.261) e la Hallucination Rate si riduce del 36% (da 0.265 a 0.170). Il fine-tuning QLoRA risulta il componente a maggiore impatto sull'apprendimento del meccanismo di astensione: la No-Answer Accuracy passa da 0.243 a 0.514, indicando che tale comportamento non emerge in modo affidabile dai soli modelli pre-addestrati e non è inducibile in maniera sufficiente mediante il solo prompt engineering.

Un risultato empiricamente rilevante è l'osservazione della regressione S2→S3: il retrieval ibrido degrada le performance ($\Delta F_1 = -0.065$) su un corpus con forte componente lessicale come MIMIC-III, con il calo più pronunciato sulle query numeriche ($\Delta F_1 = -0.240$ per la categoria `numeric_lab`). L'analisi per categoria di retrieval (Tabella 7) evidenzia come tale regressione sia causalmente attribuibile a un fallimento del retrieval sulla categoria `lab` (Recall@5 = 0.381), e non a una riduzione di recall complessiva, poiché il retriever denso supera BM25 in Recall@5 sul test set (0.558 vs 0.548). Poiché tale risultato non è statisticamente significativo, esso va interpretato con prudenza come evidenza esplorativa piuttosto che conclusiva. Nondimeno, esso motiva l'adozione di strategie di routing adattivo per il retrieval clinico, come mostrato dall'Adaptive Query Router (S5), che riduce il bias verso il retriever denso e ottiene la Hallucination Rate più bassa tra i sistemi considerati (0.160).

Nel complesso, il sistema rappresenta una *proof of concept* funzionale per il Clinical Decision Support su archivi documentali ospedalieri, ma non può essere considerato validato per uso clinico reale. Restano infatti limitazioni esplicite di generalizzabilità, copertura del dataset, variabilità linguistica e robustezza del retrieval, che rendono necessarie ulteriori fasi di validazione prima di un eventuale impiego operativo.

References

[1] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi. Self-RAG: Learning to retrieve, generate, and critique through self-reflection. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024.

[2] G. V. Cormack, C. L. A. Clarke, and S. Buettcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '09, pages 758–759. ACM, 2009.

[3] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. *Advances in Neural Information Processing Systems*, 36, 2023.

[4] R. Dror, G. Baumer, S. Shlomov, and R. Reichart. The hitchhiker's guide to testing statistical significance in natural language processing. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1383–1392. Association for Computational Linguistics, 2018.

[5] L. Gao, X. Ma, J. Lin, and J. Callan. Precise zero-shot dense retrieval without relevance labels. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1762–1777. Association for Computational Linguistics, 2023.

[6] Y. Gu, R. Tinn, H. Cheng, M. Lucas, N. Usuyama, X. Liu, T. Naumann, J. Gao, and H. Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2021.

[7] A. E. W. Johnson, T. J. Pollard, L. Shen, L.-w. H. Lehman, M. Feng, M. Ghassemi, B. Moody, P. Szolovits, L. A. Celi, and R. G. Mark. MIMIC-III, a freely accessible critical care database. *Scientific Data*, 3:160035, 2016.

[8] J. Johnson, M. Douze, and H. Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2019.

[9] Y. Labrak, A. Bazoge, E. Morin, P.-A. Gourraud, M. Rouvier, and R. Dufour. BioMistral: A collection of open-source pretrained large language models for medical domains. *arXiv preprint arXiv:2402.10373*, 2024.

[10] J. Lee, W. Yoon, S. Kim, D. Kim, S. Kim, C. H. So, and J. Kang. BioBERT: A pre-trained biomedical language representation model for biomedical text mining. In *Bioinformatics*, volume 36, pages 1234–1240. Oxford University Press, 2020.

[11] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.

[12] J. Maynez, S. Narayan, B. Bohnet, and R. McDonald. On faithfulness and factuality in abstractive summarization. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1906–1919. Association for Computational Linguistics, 2020.

[13] A. Pampari, P. Raghavan, J. Liang, and J. Peng. emrQA: A large corpus for question answering on electronic medical records. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2357–2368. Association for Computational Linguistics, 2018.

[14] P. Rajpurkar, R. Jia, and P. Liang. Know what you don't know: Unanswerable questions for SQuAD. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 784–789. Association for Computational Linguistics, 2018.

[15] N. Reimers and I. Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3982–3992. Association for Computational Linguistics, 2019.

[16] S. Robertson and H. Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.

[17] K. Singhal, S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung, N. Scales, A. Tanwani, H. Cole-Lewis, S. Pfohl, P. Payne, M. Seneviratne, P. Gamble, C. Kelly, A. Babiker, N. Sully, S. Mahdavi, C. Angermueller, T. Huang, et al. Large language models encode clinical knowledge. *Nature*, 620:172–180, 2023.